AI ProCon 开发者大会

CSDN

Bert和Transformer到底学到了什么

新浪微博 张俊林

2019.9.6

Bert和Transformer简介

探寻方法

Bert到底学到了什么

Bert及其影响

- 2018年10月提出
- 引发了NLP学术及工业界领域极大的反响
- 在各种应用中取得了各种突破性成果
- NLP领域里程碑的工作

Bert的应用效果

- QA问答领域
  - 应用Bert后，性能提升30%—70%
- 阅读理解领域
  - 应用Bert后，性能提升30%—50%
- 信息检索领域
  - 应用Bert后，短文档检索性能提升25%—106%
  - 应用Bert后，长文档检索性能提升20%—30%

Bert的应用效果

- 对话机器人领域
  - 应用Bert后，性能提升5%—40%
- 文本摘要领域
  - 应用Bert后，性能提升10%左右
- 其它应用领域
  - 中文分词
  - 文本分类
  - 文本生成……

Bert的模型改进方向

- 文本生成模型
- 结构化知识引入
- 多模态融合
- 更大更高质量的训练数据
- 更合适的训练目标和训练方法
- 多语言融合
- ……

Bert原理—Transformer

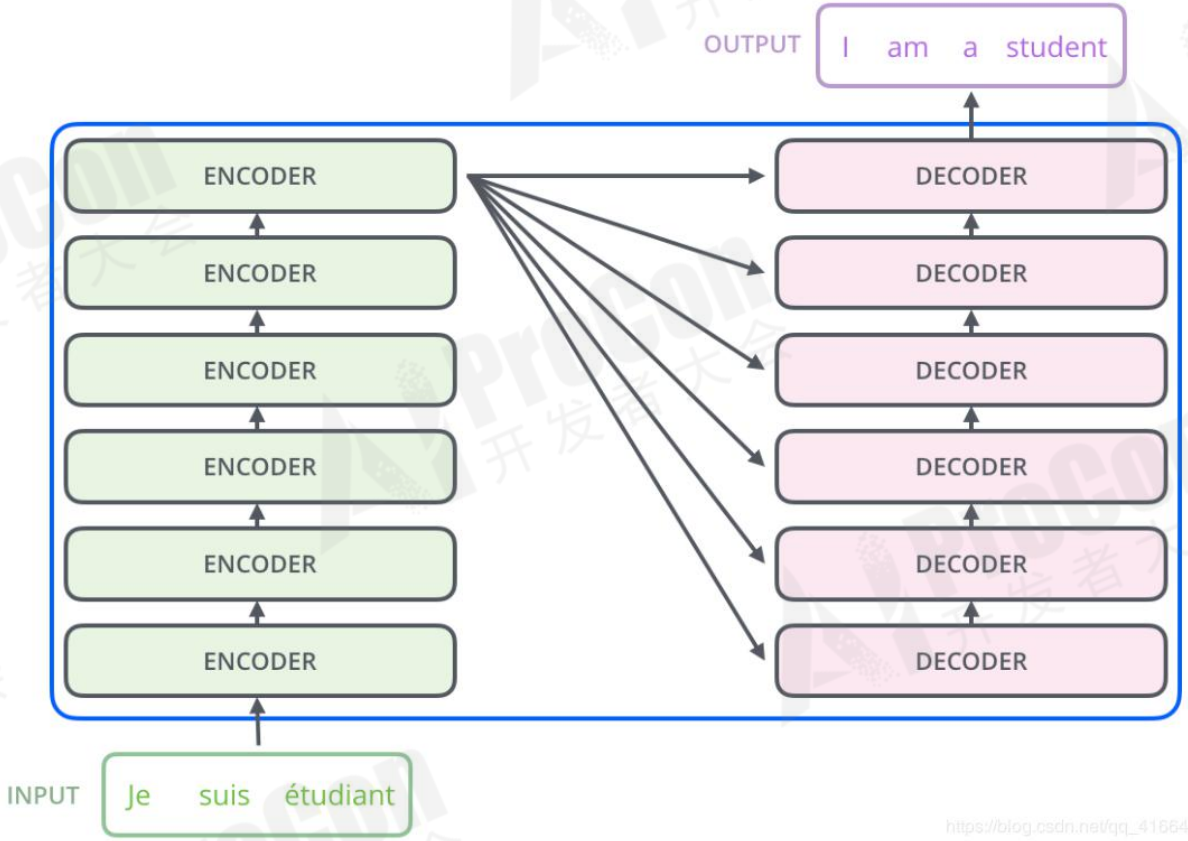

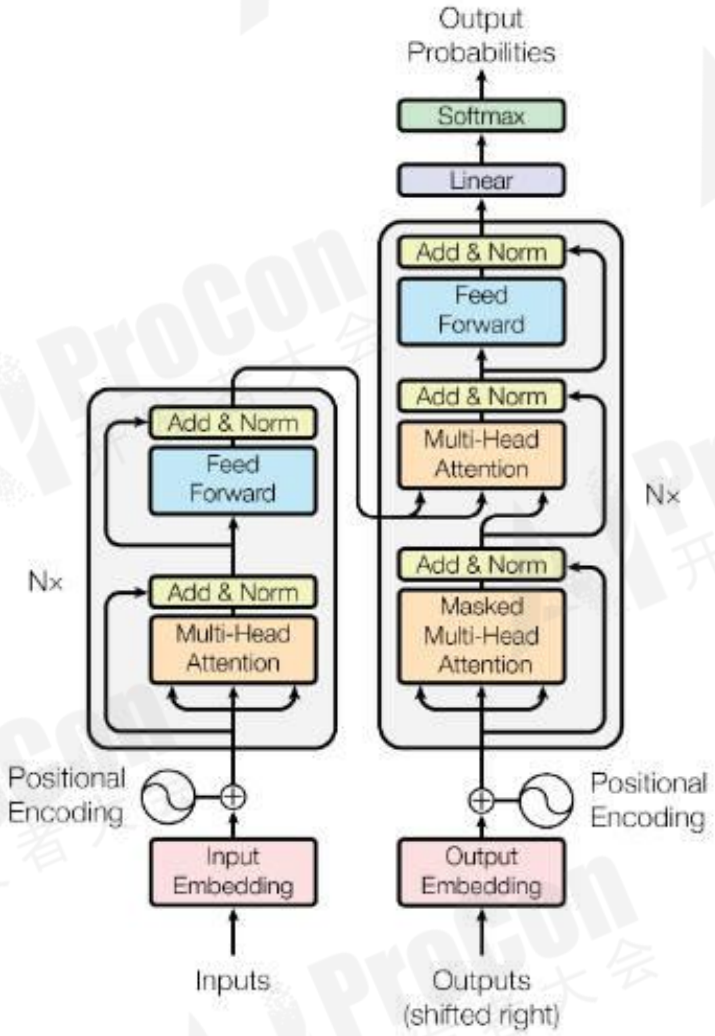

Bert原理—Transformer Block

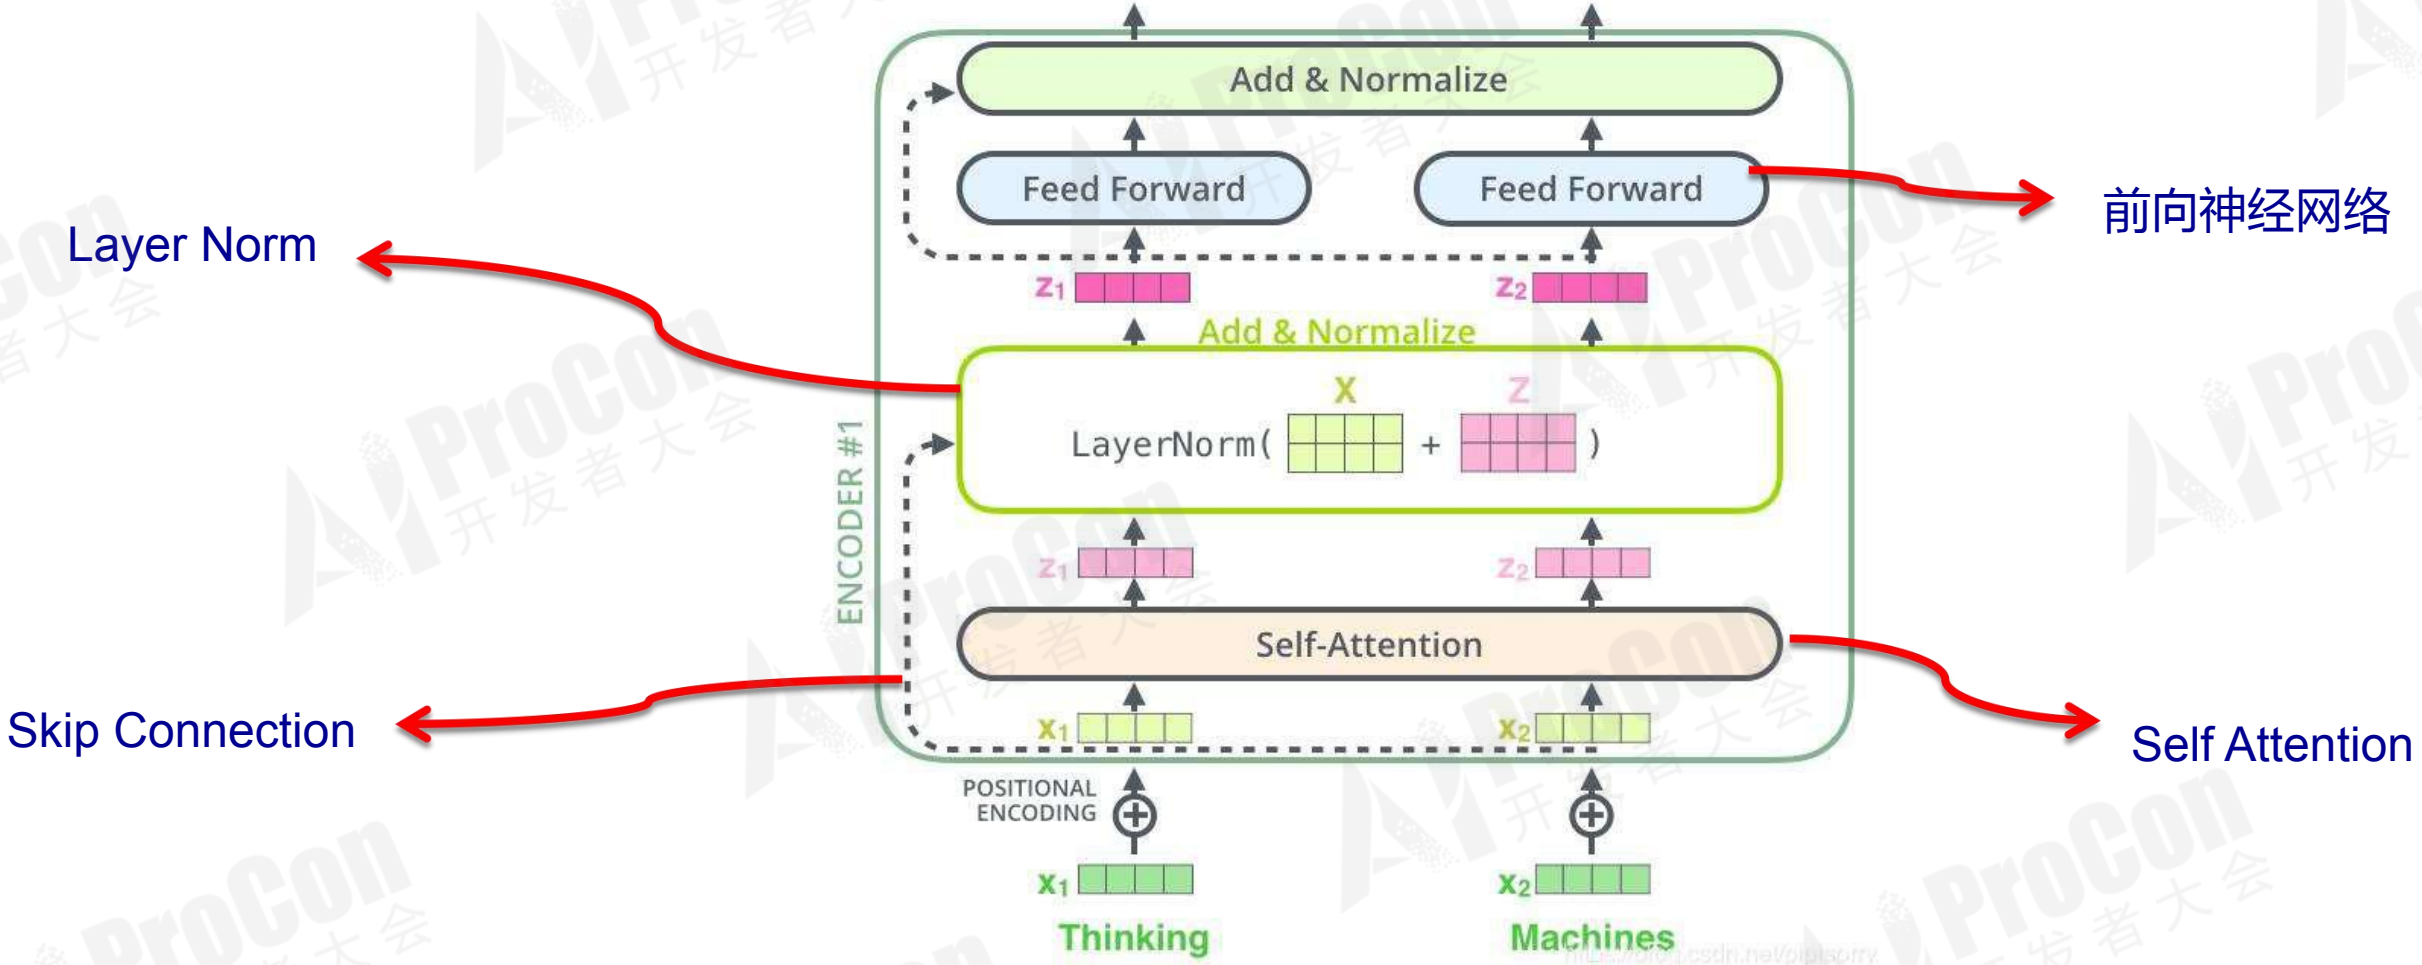

Bert原理—两阶段过程

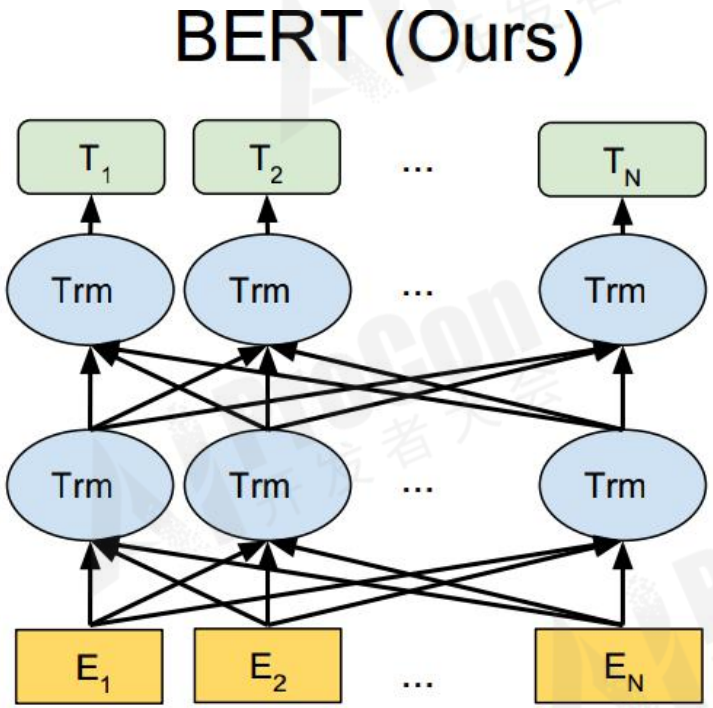

初始化参数

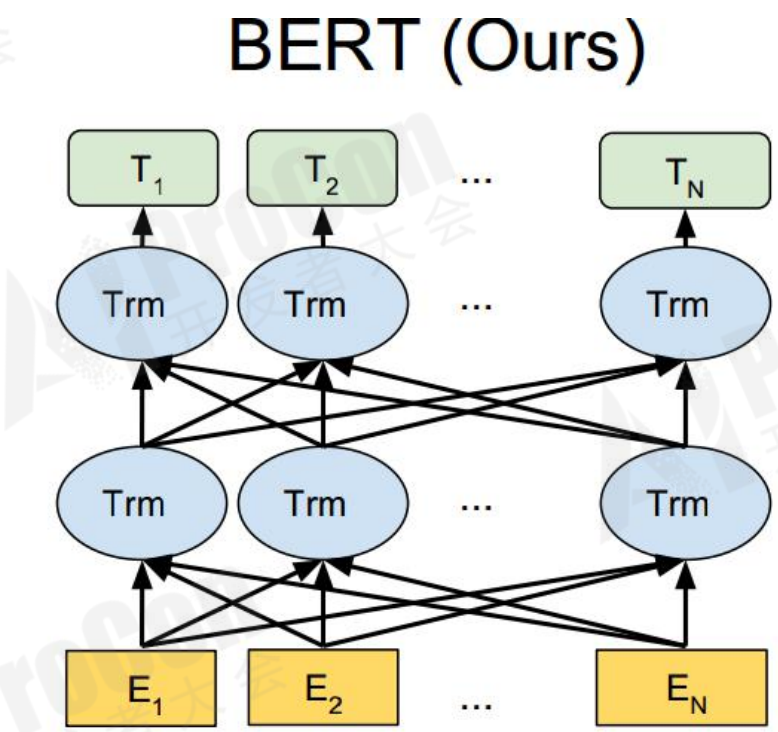

预训练
(自监督学习语言知识)

Fine-Tuning
（目标任务有监督调优）

我们的问题

为什么Bert效果这么好？

Bert里的Transformer到底学到了什么？

AI ProCon 开发者大会

CSDN

Bert和Transformer简介

探寻方法

Bert到底学到了什么

DNN是个著名的黑盒系统

特征可视化：
典型的破解黑盒的方法

每个神经元到底学到了什么？
黑盒系统！

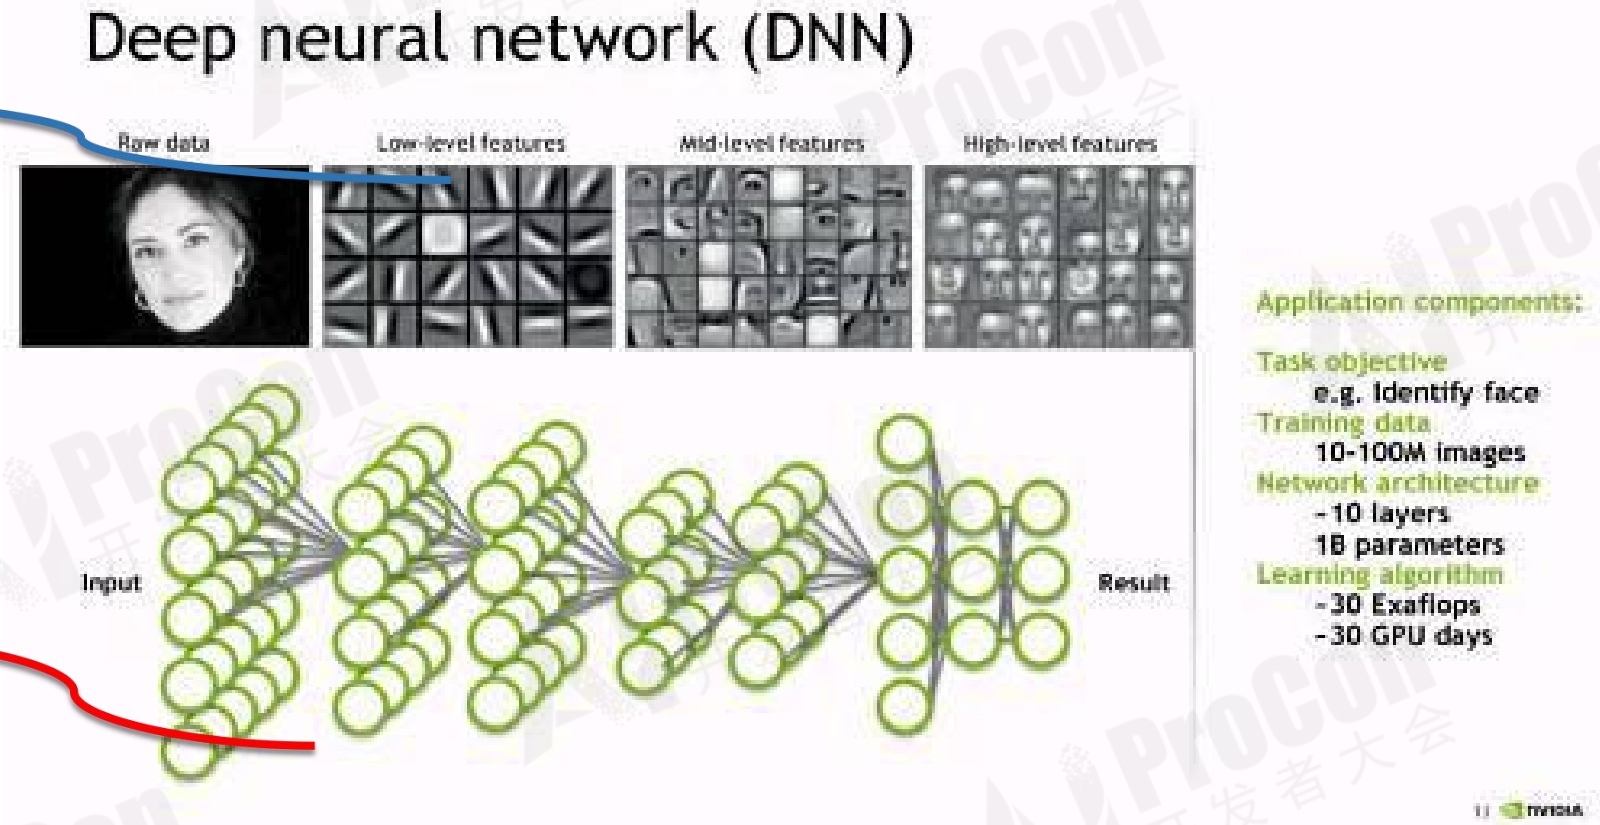

Bert和Transformer的探寻方法—可视化（2D t-SEN）

(a) Layer 1 (b) Layer 2 (c) Layer 11 (d) Layer 12

Figure 1: 2*D* t-SNE plot of span embeddings computed from the first and last two layers of BERT.

Bert和Transformer的探寻方法—可视化（Attention图）

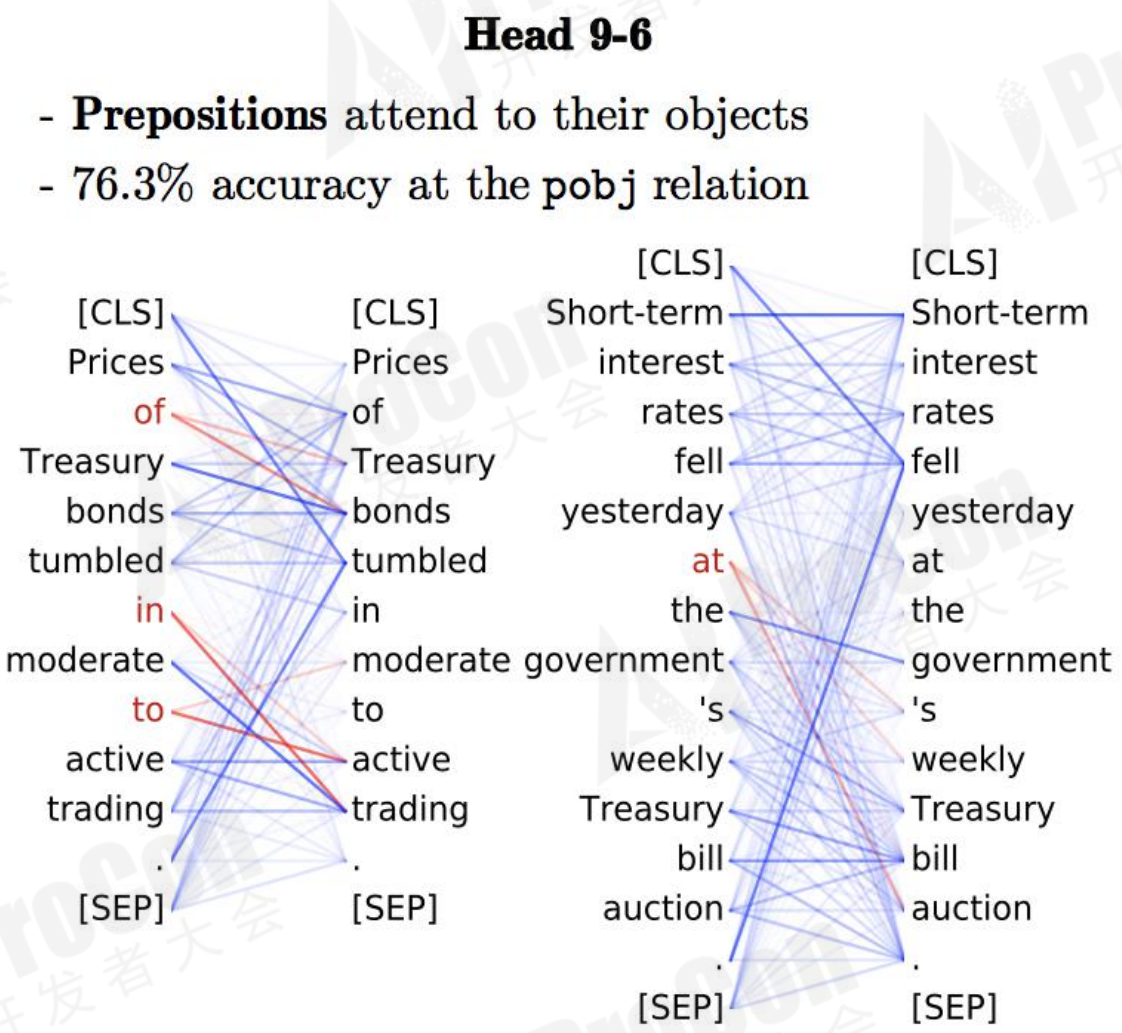

Attention图：通过可视化地表现句中单词之间的Attention强度，可以看出学到了什么知识

探寻介词与其它单词的关系

Bert和Transformer的探寻方法—Probing Classifer

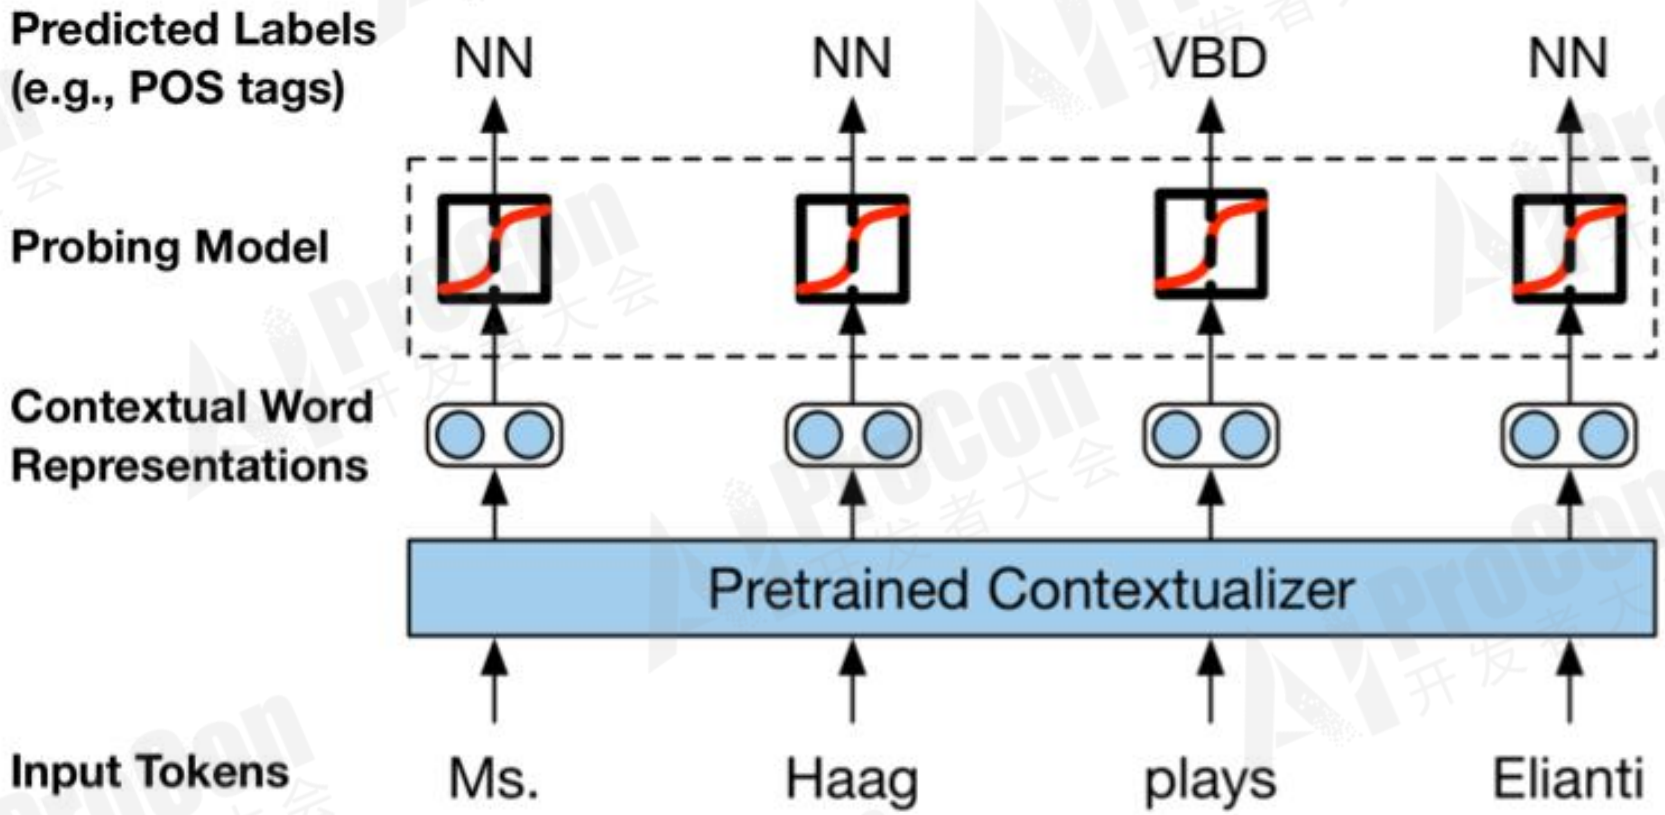

Bert和Transformer的探寻方法—Edge Probing Classifer

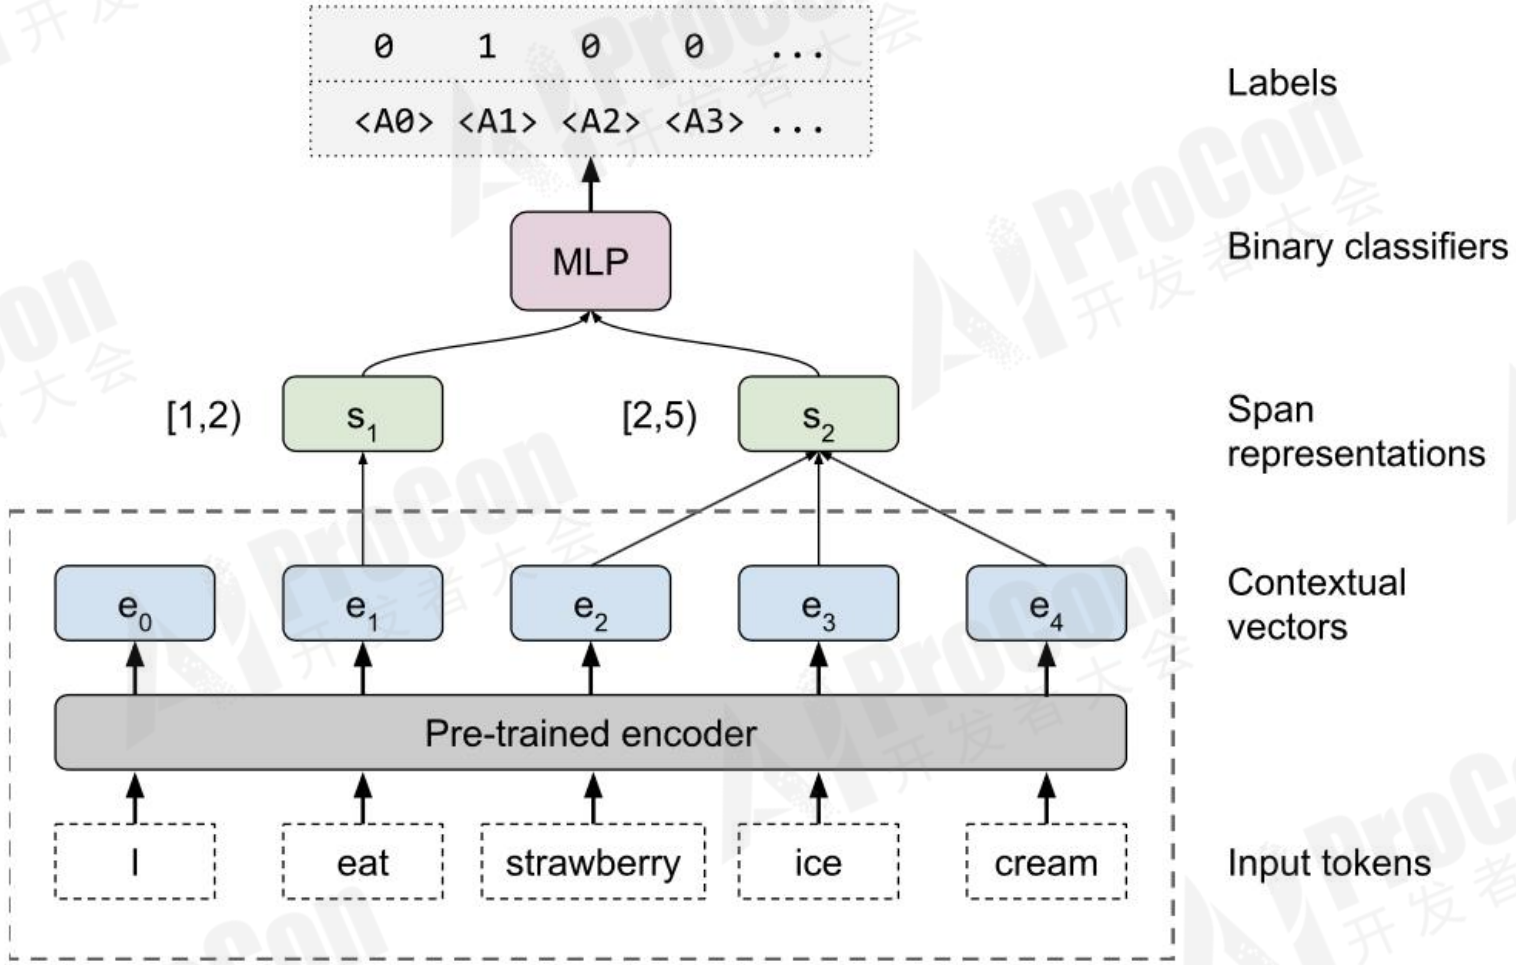

AI ProCon 开发者大会

CSDN

Bert和Transformer简介

探寻方法

Bert到底学到了什么

Bert中的Transformer如何对语言知识编码-概述

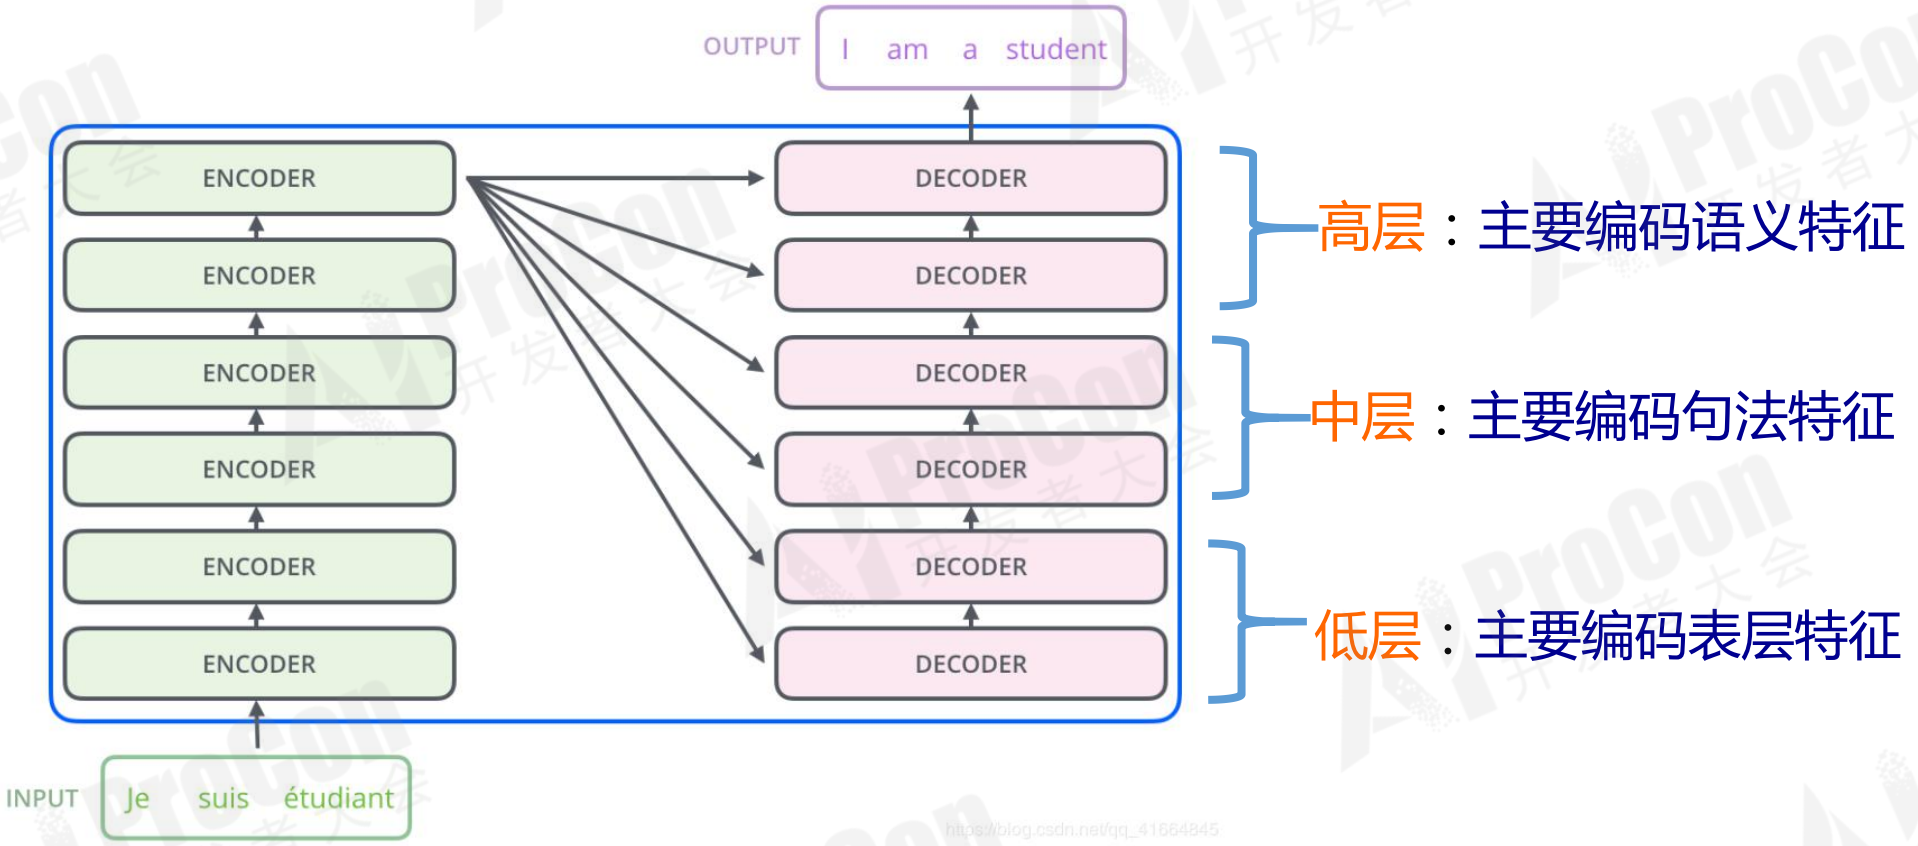

Bert中的Transformer如何对语言知识编码-概述

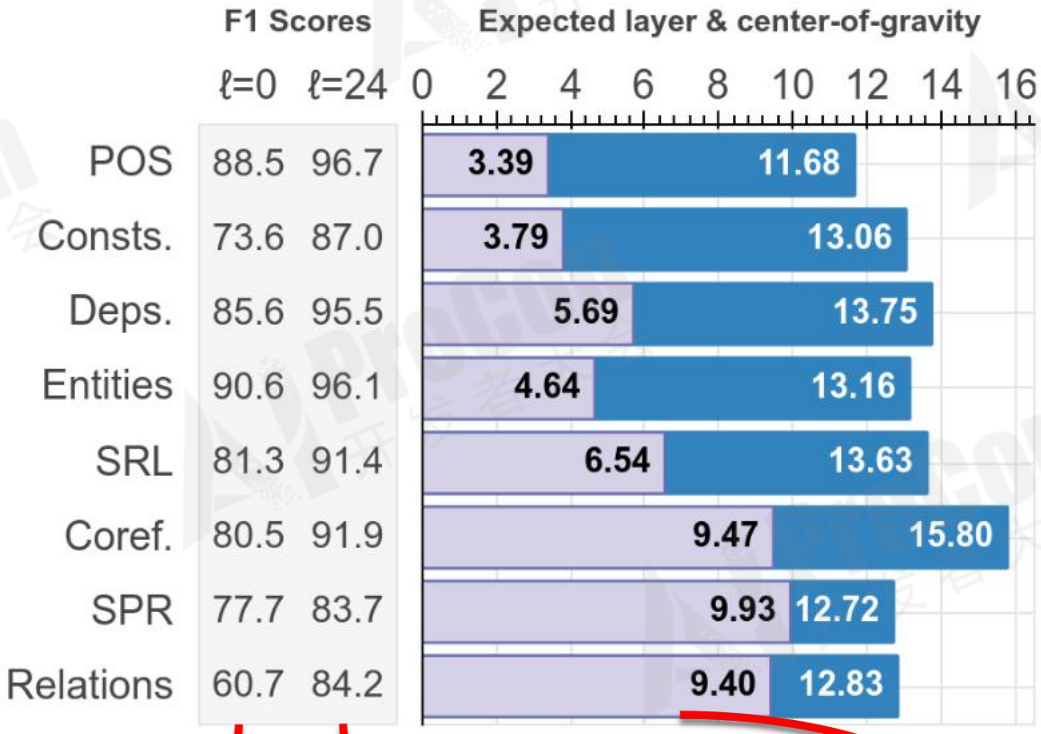

高层：主要编码语义特征

中层：主要编码句法特征

低层：主要编码表层特征

数值越大代表Transformer越高层级的作用越大

BaseLine

Full Model(Bert Large)

Bert中的Transformer如何对语言知识编码-概述

数值越大代表作用越大

句法：中低层，且具备Layer局部性

语义：不具备Layer局部性

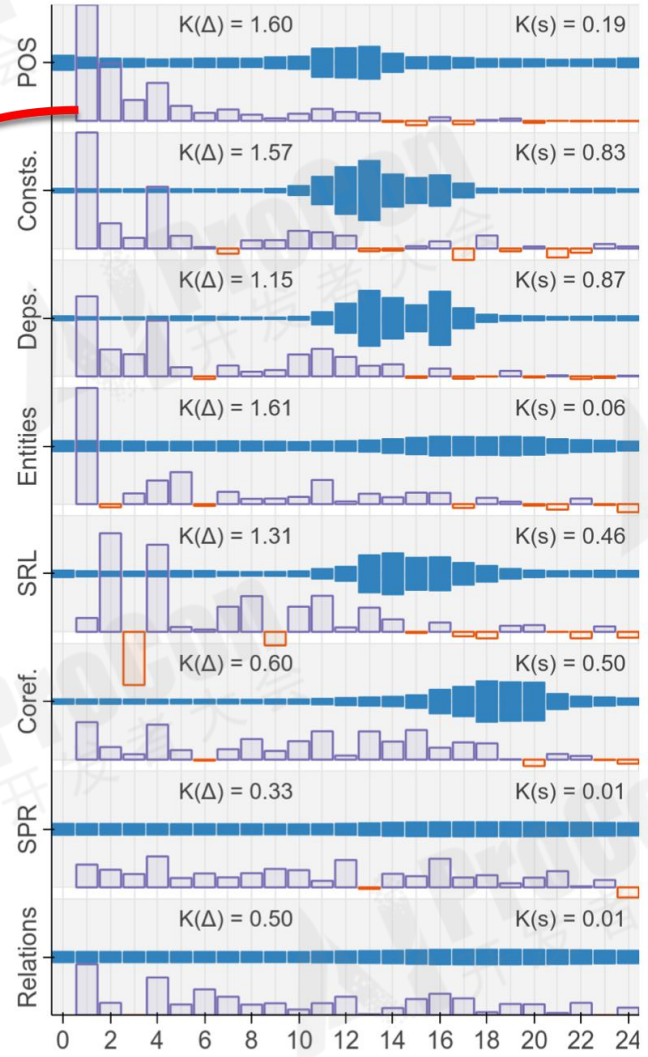

Bert中的Transformer如何对语言知识编码-概述

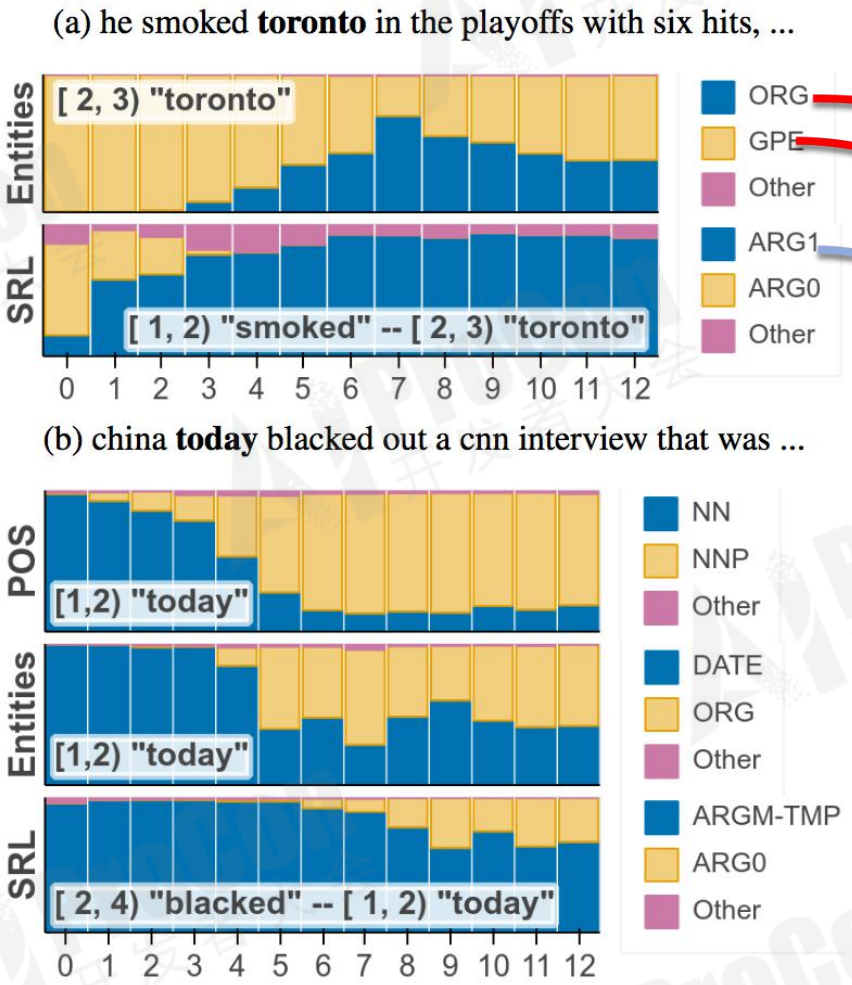

高层语义知识对低层句法知识有反馈作用

他在季后赛中抽了多伦多六支安打

he smoked toronto in the playoffs with six hits

多伦多（地名） vs 多伦多队（专名）？

Toronto受动/Smoke施动

低层Transformer Layer-对单词位置信息的编码

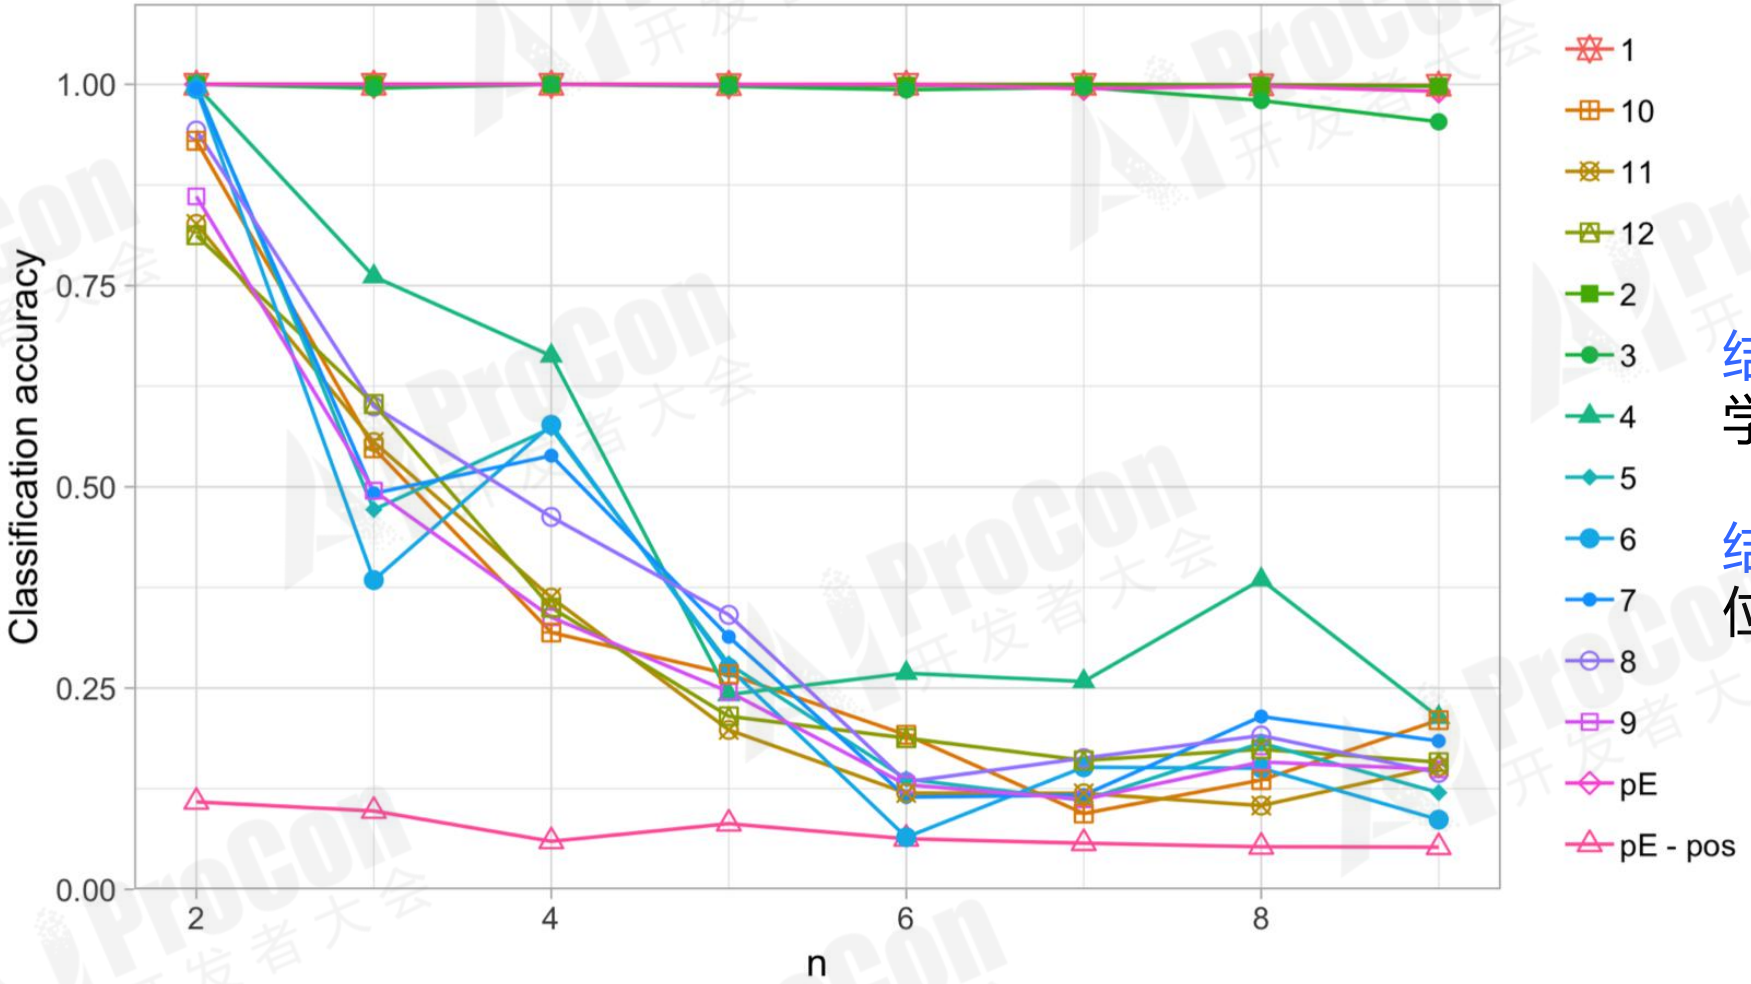

任务：预测单词位置

结论1:低层Transformer Layer学习单词位置信息；

结论2:高层Layer已经不记录位置信息，更关注层级结构；

低层Transformer Layer-对短语信息的编码

(a) Layer 1 (b) Layer 2 (c) Layer 11 (d) Layer 12

Figure 1: 2*D* t-SNE plot of span embeddings computed from the first and last two layers of BERT.

任务：短语聚类

结论：低层Layer能很好区分短语聚类，高层混杂在一起

低层Transformer Layer-对特殊符号的编码

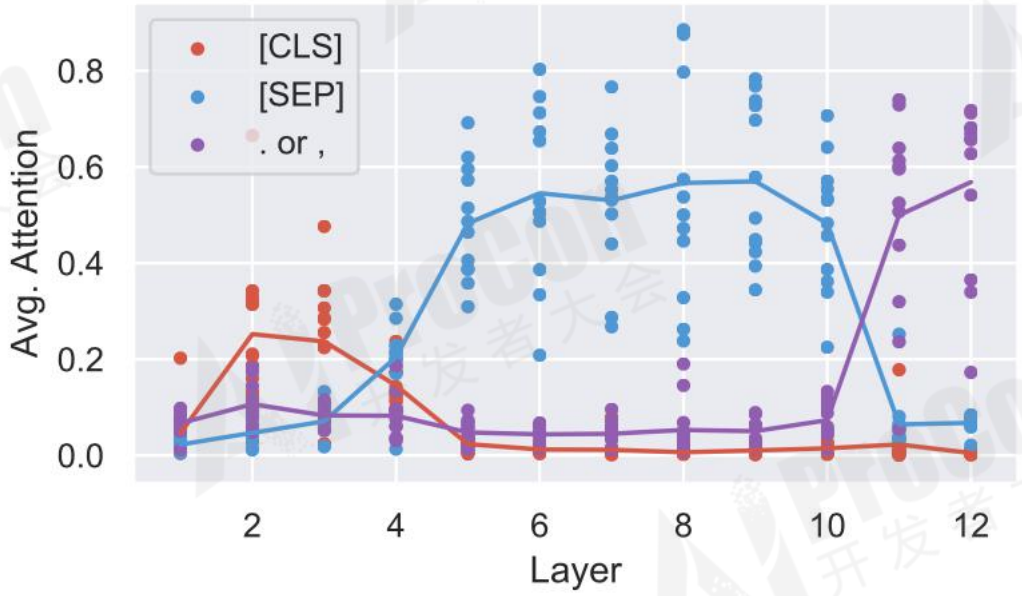

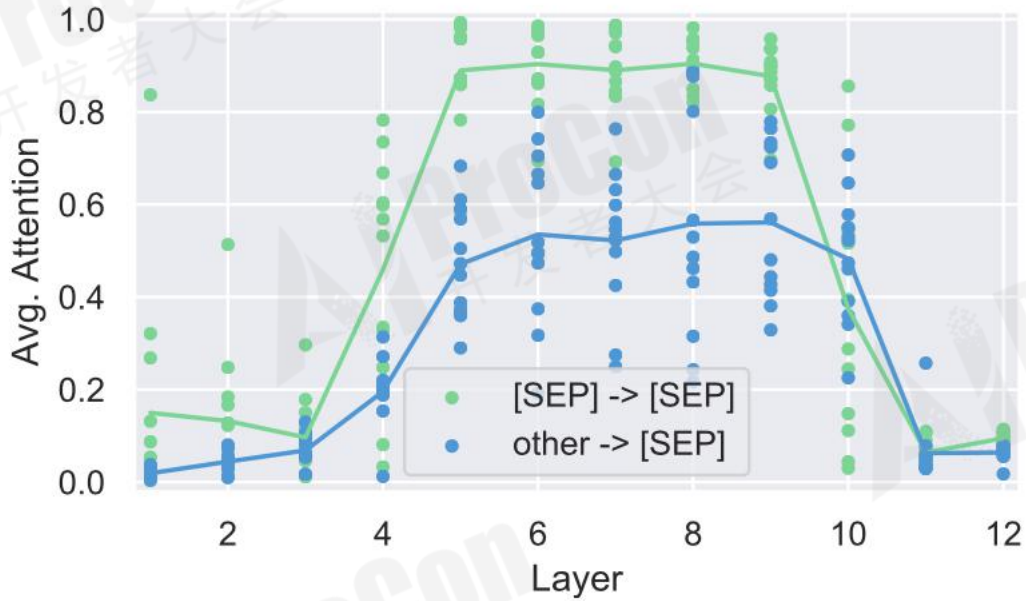

低层级Head： 注重[CLS]起始符号；
中间层级Head：注重句子分割符号[SEP]
高层级的Head：注重句号和逗号标点符号；

[SEP]也特别注重[SEP]起始符号；

中层Transformer Layer-对句法信息的编码

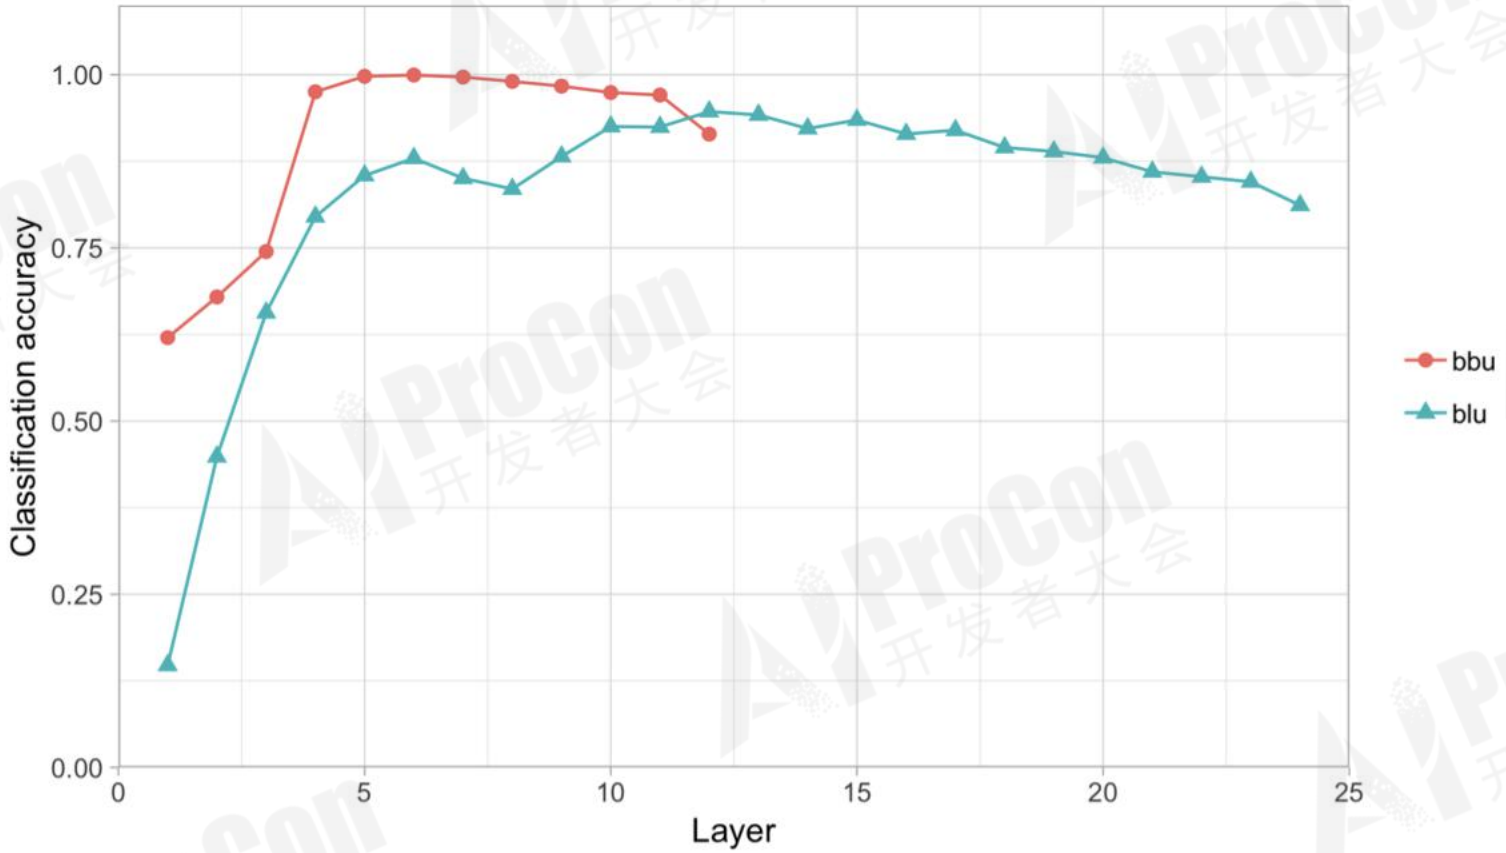

句法预测任务

- 中间层编码了更多的句法信息

中层Transformer Layer-对句法信息的编码

Relation	Head	Accuracy	Baseline
All	7-6	34.5	26.3 (1)
prep	7-4	66.7	61.8 (-1)
pobj	9-6	**76.3**	34.6 (-2)
det	8-11	**94.3**	51.7 (1)
nn	4-10	70.4	70.2 (1)
nsubj	8-2	58.5	45.5 (1)
amod	4-10	75.6	68.3 (1)
dobj	8-10	**86.8**	40.0 (-2)
advmod	7-6	48.8	40.2 (1)
aux	4-10	81.1	71.5 (1)
poss	7-6	**80.5**	47.7 (1)
auxpass	4-10	**82.5**	40.5 (1)
ccomp	8-1	**48.8**	12.4 (-2)
mark	8-2	**50.7**	14.5 (2)
prt	6-7	**99.1**	91.4 (-1)

句法任务：

语料：Wall Street Journal portion of the Penn Treebank

- 探测Attention Head的句法能力
- 没有Attention Head具备全面的句法特征表达能力
- Attention Head具备句法特征能力特异性
- 句法能力集中在Transformer中间层
- Bert捕获的句法特征有些和人定义的标准不同

高层Transformer Layer-指代消解

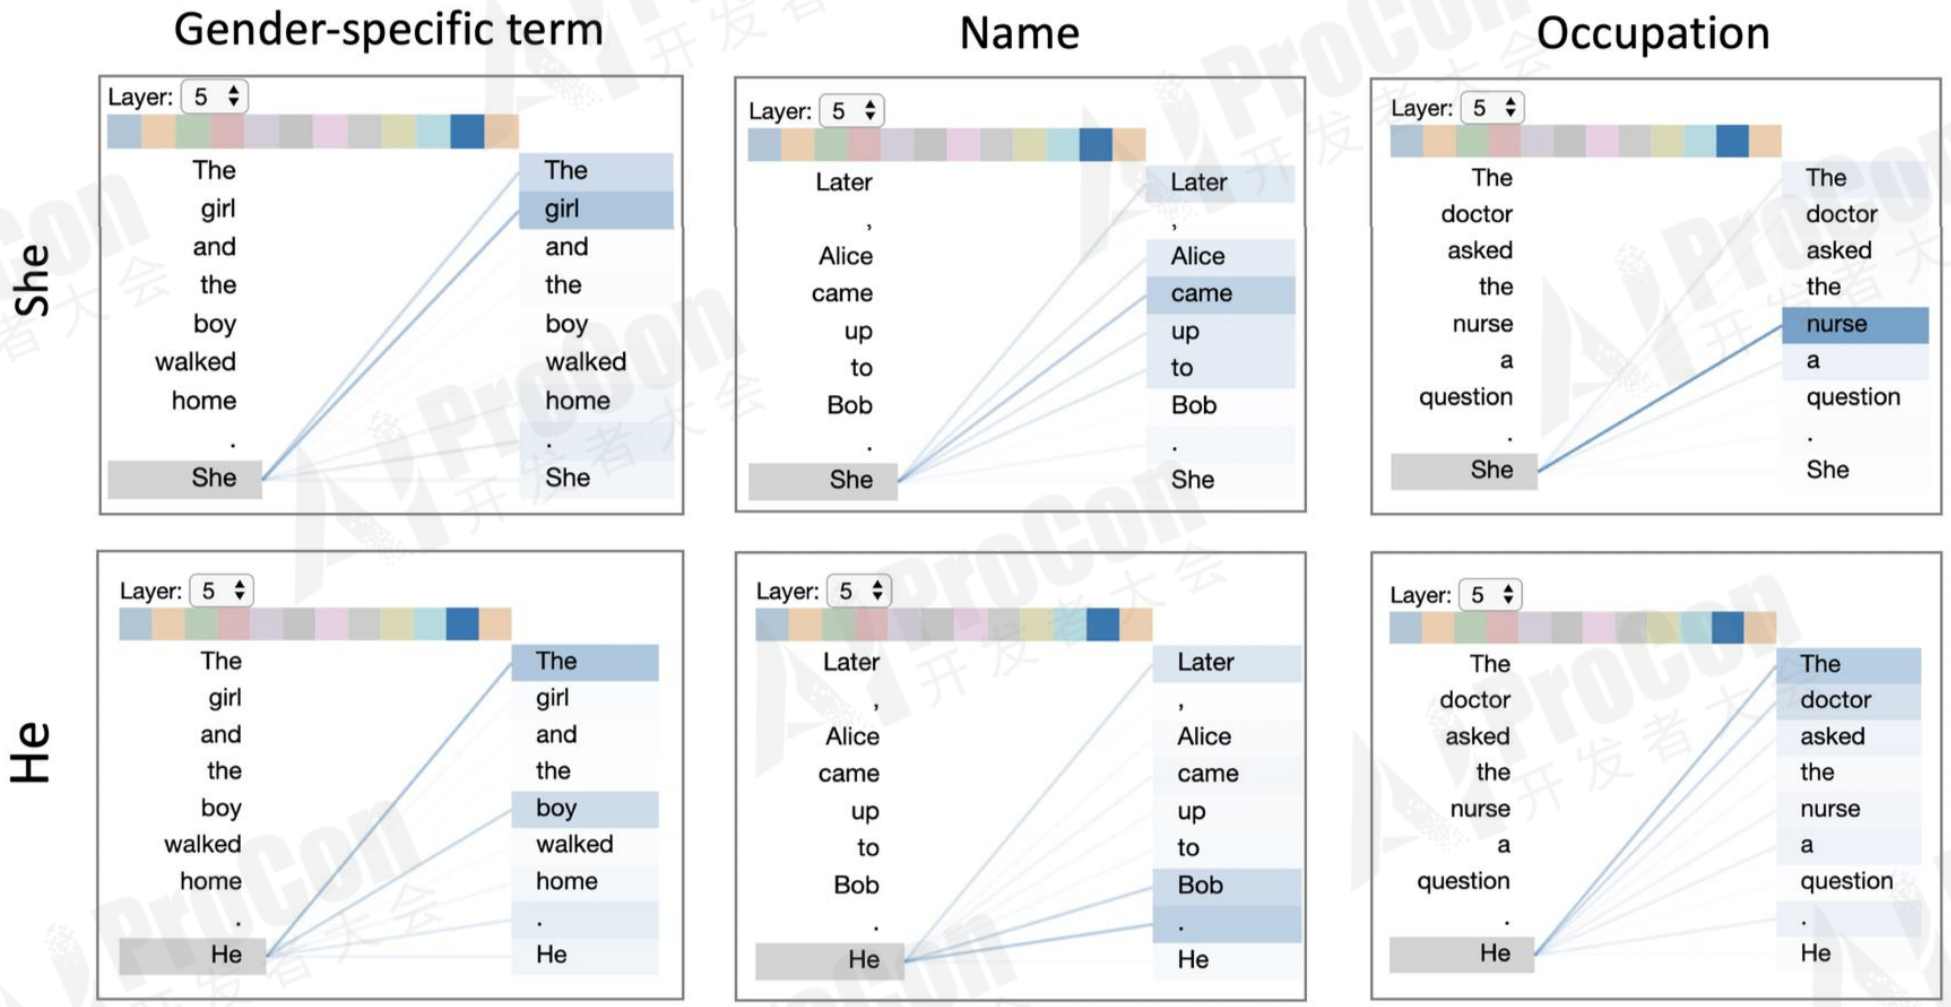

Bert学习指代消解类特征：He vs She

Bert的预训练过程比非预训练过程多学了什么

BERT (Ours)

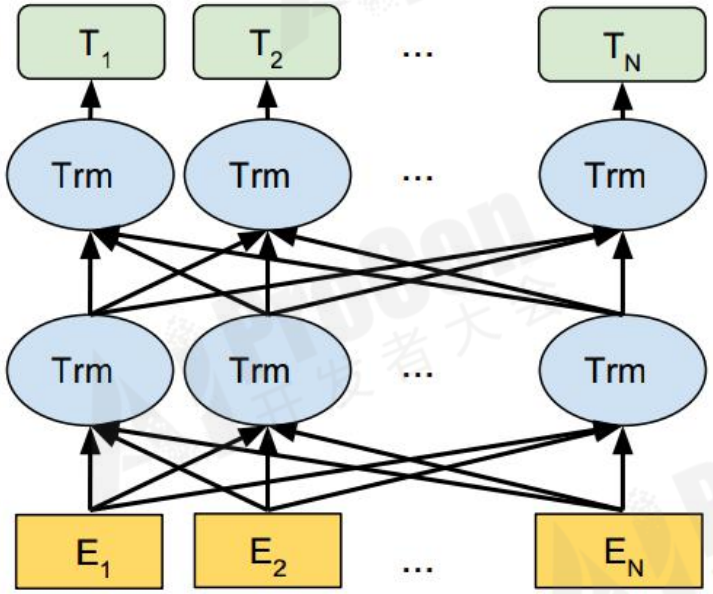

有预训练过程

BERT (Ours)

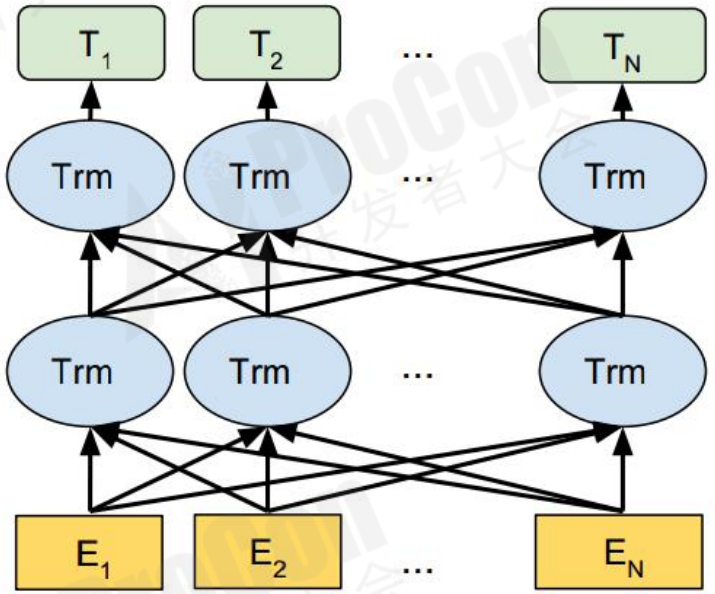

无预训练过程

做监督任务Finetuning后，有什么差异？

表现：未训练Bert在句子长度预测任务好于预训练过程Bert

结论：预训练模型牺牲部分表层特征表达能力，获得更多更丰富的复杂特征

预训练模型（Bert/ELMO/GPT)学到了些什么

	CoVe			ELMo			GPT		
	Lex.	Full	Abs. Δ	Lex.	Full	Abs. Δ	Lex.	cat	mix
Part-of-Speech	85.7	94.0	8.4	90.4	**96.7**	6.3	88.2	94.9	95.0
Constituents	56.1	81.6	25.4	69.1	**84.6**	15.4	65.1	81.3	**84.6**
Dependencies	75.0	83.6	8.6	80.4	**93.9**	13.6	77.7	92.1	**94.1**
Entities	88.4	90.3	1.9	92.0	**95.6**	3.5	88.6	92.9	92.5
SRL (all)	59.7	80.4	20.7	74.1	**90.1**	16.0	67.7	86.0	89.7
Core roles	*56.2*	*81.0*	*24.7*	*73.6*	***92.6***	*19.0*	*65.1*	*88.0*	*92.0*
Non-core roles	*67.7*	*78.8*	*11.1*	*75.4*	***84.1***	*8.8*	*73.9*	*81.3*	***84.1***
OntoNotes coref.	72.9	79.2	6.3	75.3	84.0	8.7	71.8	83.6	**86.3**
SPR1	73.7	77.1	3.4	80.1	**84.8**	4.7	79.2	83.5	83.1
SPR2	76.6	80.2	3.6	82.1	83.1	1.0	82.2	**83.8**	**83.5**
Winograd coref.	52.1	**54.3**	2.2	**54.3**	**53.5**	-0.8	51.7	52.6	**53.8**
Rel. (SemEval)	51.0	60.6	9.6	55.7	77.8	22.1	58.2	**81.3**	**81.0**
Macro Average	69.1	78.1	9.0	75.4	**84.4**	9.1	73.0	83.2	**84.4**

Cove/ELMO/GPT
相对基准方法，多编码了更多句法信息；
语义相对少些；

预训练模型（Bert/ELMO/GPT)学到了些什么

	BERT-base F1 Score			Abs. Δ	BERT-large F1 Score			Abs. Δ	
	Lex.	cat	mix	ELMo	Lex.	cat	mix	(base)	ELMo
Part-of-Speech	88.4	**97.0**	96.7	0.0	88.1	96.5	**96.9**	0.2	0.2
Constituents	68.4	83.7	86.7	2.1	69.0	80.1	**87.0**	0.4	2.5
Dependencies	80.1	93.0	95.1	1.1	80.2	91.5	**95.4**	0.3	1.4
Entities	90.9	96.1	96.2	0.6	91.8	96.2	**96.5**	0.3	0.9
SRL (all)	75.4	89.4	91.3	1.2	76.5	88.2	**92.3**	1.0	2.2
Core roles	*74.9*	*91.4*	*93.6*	*1.0*	*76.3*	*89.9*	***94.6***	*1.0*	*2.0*
Non-core roles	*76.4*	*84.7*	*85.9*	*1.8*	*76.9*	*84.1*	***86.9***	*1.0*	*2.8*
OntoNotes coref.	74.9	88.7	90.2	6.3	75.7	89.6	**91.4**	1.2	7.4
SPR1	79.2	84.7	**86.1**	1.3	79.6	85.1	**85.8**	-0.3	1.0
SPR2	81.7	83.0	**83.8**	0.7	81.6	83.2	**84.1**	0.3	1.0
Winograd coref.	54.3	53.6	54.9	1.4	53.0	53.8	**61.4**	6.5	7.8
Rel. (SemEval)	57.4	78.3	82.0	4.2	56.2	77.6	**82.4**	0.5	4.6
Macro Average	75.1	84.8	86.3	1.9	75.2	84.2	**87.3**	1.0	2.9

Bert vs. ELMO

更深的结构有利于复杂语义任务；

预训练模型（Bert/ELMO/GPT)学到了些什么

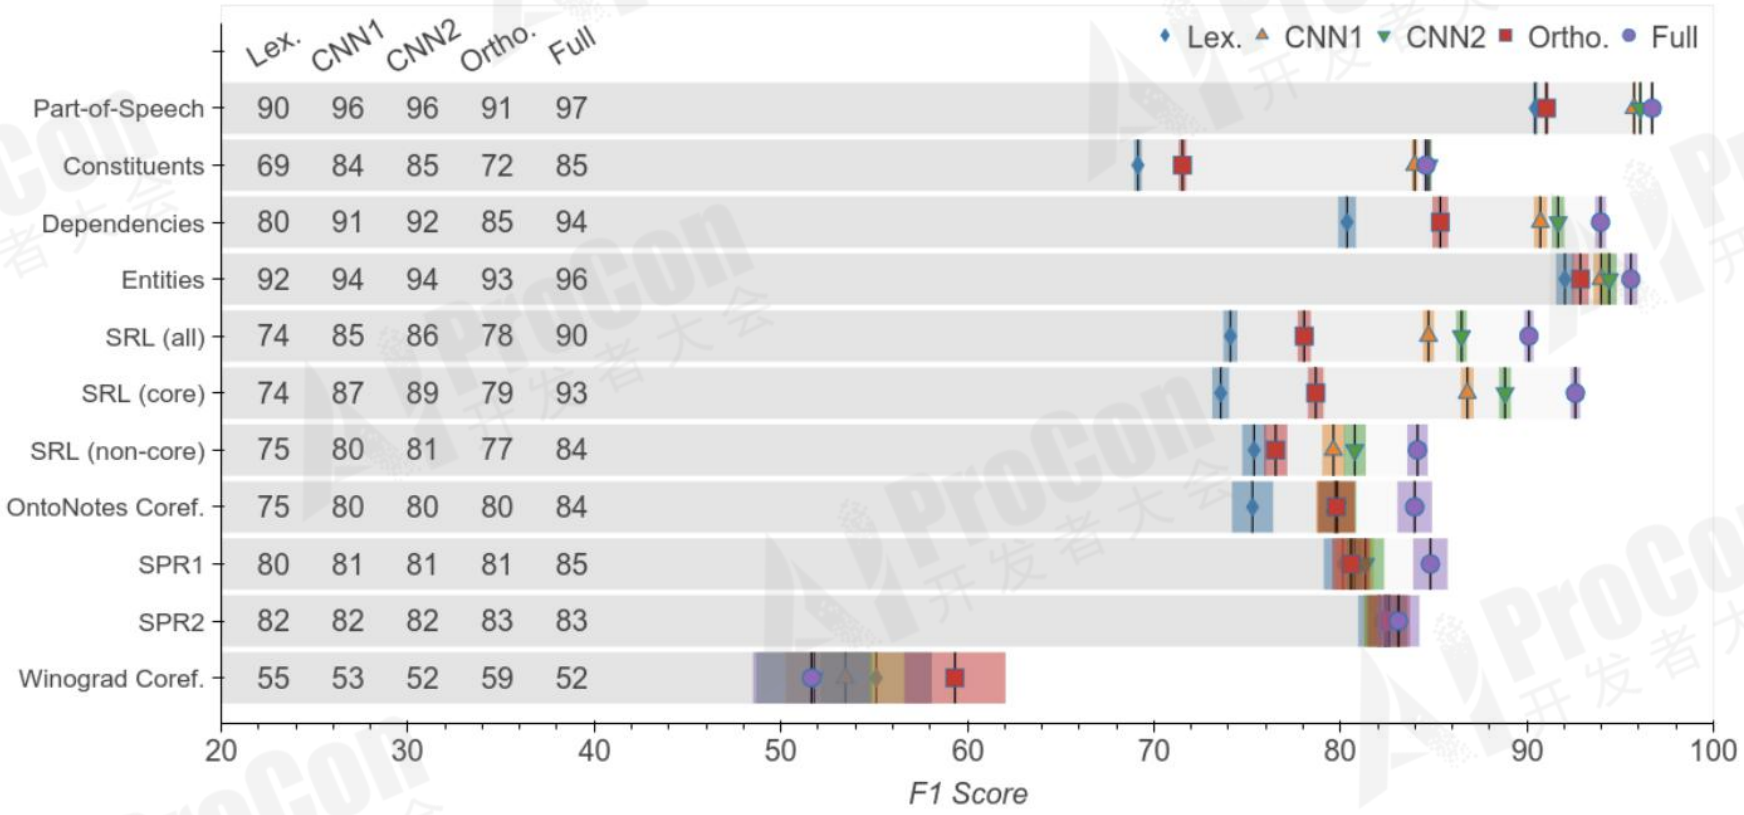

Lex:基准
CNN1:左右窗口大小1
CNN2:左右窗口大小2
Ortho:未预训练ELMO
Full:　预训练ELMO

ELMO：捕获了更长的上下文

CSDN

AI ProCon

开发者大会